

# Rapport Projet Final de Mise en place d'un écosystème

Par Richard Simoneau

Le projet porte sur un modèle d'intelligence artificielle de prédiction des maladies du cœur basé sur une base de données fournie sur le site de kaggle dont voici le lien : <https://www.kaggle.com/code/georgyzubkov/heart-disease-exploratory-data-analysis>

Le sujet m'a interpellé d'emblée car je suis moi-même atteint d'une de ces maladie, l'hypertensions artérielle.

Sur le site d'où je me suis inspiré pour les étapes de résolution et/ou validation du choix de modèle à utiliser, j'ai choisi la régression logistique car elle donnait des résultats plus précis et à part la régression linéaire, je ne connais pas les autres modèles et ne voulais pas copier le code non-plus.

L'étape d'exploration des données fut un peut décevante car elles sont loin d'être vraiment scientifiques. Plusieurs données sont suggestives et ne peuvent pas vraiment être considérées comparable entre les patients. Un patient peut considérer se sentir mal un jour et le comptabiliser, mais un autre patient, lui, aurait pu se considérer très bien dans les mêmes circonstances.

J'ai quand même continué le projet car il n'en est pas un orienté vers un véritable outil de diagnostic pour les professionnels de la santé. Pour se faire, il faudrait impliquer plusieurs avis de professionnels en ce domaine pour valider les données sélectionnées pour entraîner le model.

Donc pour l'entraînement du model, il n'y a pas vraiment d'hyperparamètres à ajuster dans la régression logistique. C'est le choix du modèle qui importe. Dans un contexte plus professionnel, j'aurais utilisé plusieurs model pour faire des comparaisons et selon le résultat, j'aurais utilisé le meilleur. Étant donné que sur le site de Kaggle, les exemples étaient tous là avec leurs résultats, j'ai décidé de choisir d'office le meilleur pour me concentrer sur le but final du projet qui est de voir toutes les étapes du processus.

La transformation et la validation des données fut quand même assez simple étant donné qu'elles étaient déjà nettoyées. Donc pour la validation du pipeline, j'ai créé un nouveau fichier avec les mêmes valeurs, mais en y introduisant des erreurs. Je n'ai cependant pas poussé la validation plus loin que des données manquantes car j'aurais porter les deux chapeaux, celui qui fait les erreurs et celui qui les corrige. Dans un contexte professionnel, un maximum de cas de figure serait à coder pour valider les données.

Dans le cas de l'utilisation de l'utilisateur, j'ai quand même fait une validation que le fichier entré par l'utilisateur était valide/existant, qu'il avait entré un fichier avec l'extension « .csv » et que les noms de colonnes étaient les bonnes.

Pour la sortie, « output », j'ai ajouté simplement la colonne de prédiction du model à savoir si le patient va développer une maladie du cœur ou non. J'ai sauvegardé le fichier en format csv et j'ai fait afficher les premières lignes des résultats. Dans un contexte plus développé, il serait préférable de sauvegarder les résultats dans un fichier Excel pour pouvoir surligner les prédictions positive en une couleur différente et y ajouter des graphiques statistiques.

En rédigeant ce rapport, il m'est venue l'idée que le projet pourrait être poussé vers un site web ou il y aurait un formulaire à remplir. Ce dernier serait les données pour le model et le résultat pourrait être donnée après les avoirs soumis au model en arrière-plan.

Pour conclure, ce projet en était un d'apprentissage, mais le potentiel est là pour une réelle exploitation de la force de l'IA afin de prévenir les maladies du cœur. Il faudrait seulement impliquer plusieurs ressources et rechercher les réelles valeurs de prédiction.